RAPPORT 1

Classification automatisée de cellules sanguines par apprentissage profond

Exploration des données · Data visualisation · Pré-processing · Modélisation

Participants

Joseph Fonlupt · Romain Hild · Rémi Launay

2026

Sommaire

Sommaire **2**
1. Contexte **3**
1.1 Objectifs 3
2. Données et exploration **4**
2.1 Sources de données 4
2.2 Pertinence et limites des données 4
2.3 Visualisations et statistiques 5
3. Pré-processing et préparation des données **9**
3.1 Fusion et contrôle qualité 9
3.2 Standardisation des images 9
3.3 Étude des transformations de pré-processing 10
3.4 Sélection des classes 10
3.5 Data augmentation 11
4. Modélisation et expérimentations **11**
4.1 Classification binaire par cellule 11
4.2 Évaluation du domain gap par CNN binaire 12
4.3 Classification multi-classes et stratégies de rééquilibrage 13
5. Conclusion et perspectives **14**
6. Références bibliographiques **14**

1. Contexte

Ce projet s'inscrit dans une démarche d'analyse et de classification automatisée de cellules sanguines à partir d'images de frottis sanguins.

D'un point de vue technique, il repose sur l'exploitation de données d'imagerie, leur exploration, leur visualisation et leur pré-processing afin de constituer un jeu de données adapté à l'entraînement de modèles de machine learning.

Sur le plan économique, l'automatisation de certaines étapes d'analyse peut contribuer à réduire le temps consacré aux tâches répétitives et à améliorer l'efficacité du processus d'analyse.

D'un point de vue scientifique, le projet s'appuie sur les méthodes de traitement d'image et d'apprentissage automatique pour étudier les caractéristiques permettant de différencier les différents types de cellules sanguines. L'exploration et le pré-processing constituent ainsi une étape essentielle pour évaluer la qualité des données, identifier leurs éventuelles limites et préparer leur utilisation dans les étapes de modélisation.

1.1 Objectifs

L'objectif principal de cette étape est de préparer et exploiter un jeu de données d'images de cellules sanguines afin de permettre leur classification automatique. Il s'agit dans un premier temps d'explorer les données pour en évaluer la qualité, la répartition et les caractéristiques, puis de réaliser les étapes de visualisation et de pré-processing nécessaires à leur utilisation. Le preprocessing vise ainsi à obtenir un jeu de données fiable, homogène et adapté à l'entraînement et à l'évaluation d'un modèle de classification.

Les membres du groupe présentent des compétences complémentaires autour de la problématique de classification des cellules sanguines. L'exploration des données, leur visualisation, le contrôle de qualité, le pré-processing et les expérimentations de modélisation ont été menés de manière complémentaire afin de relier les caractéristiques observées dans les données aux performances de classification.

Les travaux d'exploration portent notamment sur l'analyse des métadonnées, la visualisation des distributions, l'identification des différences entre les sources de données ainsi que sur les premières étapes de nettoyage et de pré-processing. Cette approche permet de caractériser la structure et la qualité du jeu de données avant la phase de modélisation.

Les travaux de modélisation portent sur des modèles de classification binaire, avec un modèle dédié à chaque type de cellule, afin d'évaluer directement la capacité des données à permettre la discrimination entre les classes. Cette approche permet

également d'identifier certains problèmes de qualité ou de nettoyage des données à partir des erreurs de classification observées.

Les différentes approches sont donc complémentaires : l'exploration et le pré-processing permettent de comprendre et de fiabiliser les données, tandis que les modèles permettent de confronter ces choix à leur impact sur les performances de classification.

2. Données et exploration

2.1 Sources de données

Le projet s'appuie sur deux jeux de données d'images de cellules sanguines : **PBC Dataset Normal DIB**, disponible sur Mendeley Data, et **PKG-AML-Cytomorphology_LMU**, disponible sur The Cancer Imaging Archive. Ces deux jeux de données sont accessibles librement et regroupent des images de cellules sanguines provenant de sources différentes.

Le jeu de données PBC contient **17 092 images** de cellules individuelles acquises au laboratoire central de l'hôpital de Barcelone. Les images ont été capturées à partir d'individus sans infection, sans maladie hématologique ou oncologique, et ne suivant aucun traitement pharmacologique au moment du prélèvement sanguin.

Le jeu de données LMU contient **18 365 images** de cellules uniques annotées par des experts, prélevées sur des frottis de sang périphérique de 100 patients diagnostiqués avec une leucémie myéloïde aiguë (LMA) à l'hôpital universitaire de Munich entre 2014 et 2017, ainsi que de 100 patients ne présentant aucun signe de pathologie hématologique maligne.

Les deux datasets contiennent donc un total de **35 457 images**.

2.2 Pertinence et limites des données

Les **images des cellules** constituent les données d'entrée du modèle, et la variable cible est donc le **type de cellule** identifier par l'entête du fichier.

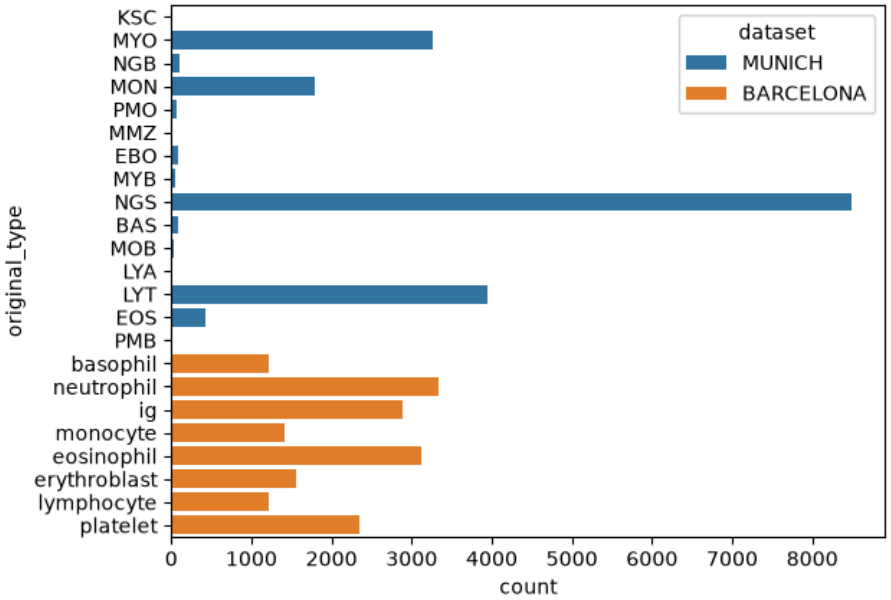
Une particularité importante du jeu de données est qu'il regroupe deux sources différentes, **PBC** et **LMU**. Les images présentent également des caractéristiques différentes selon leur source(format, qualitée, colorimétrie). Cette différence entre les sources constitue notamment un élément à prendre en compte lors de l'exploration et du pré-processing des données. Les classes ne sont également pas réparties de manière homogène, certaines catégories étant davantage représentées que d'autres. Ces différences nécessitent une harmonisation des données avant leur utilisation pour la classification.

Les principaux facteurs limitants sont donc le fort **déséquilibre de classes**, autant intra et inter source, et l'**hétérogénéité entre les deux sources de données**. Les différences de résolution, de caractéristiques visuelles et de répartition des classes peuvent introduire

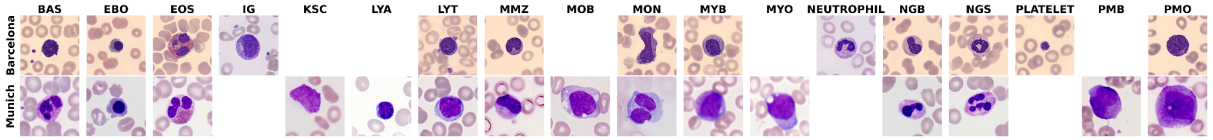
un biais dans l'apprentissage du modèle. Ces éléments doivent être pris en compte lors du pré-processing et de la constitution des jeux d'entraînement, de validation et de test.

2.3 Visualisations et statistiques

L'exploration visuelle et statistique a permis de caractériser la structure des deux jeux de données et d'identifier les principales différences entre les sources. Les premières visualisations portent sur la répartition des classes. Le dataset PBC comporte **12 classes**, tandis que le dataset LMU en comporte **15**, avec une répartition très différente du nombre d'images entre les classes. Le déséquilibre est particulièrement marqué dans LMU, avec un rapport de **765,1 entre la classe la plus représentée et la moins représentée**, contre **2,7 pour PBC**.



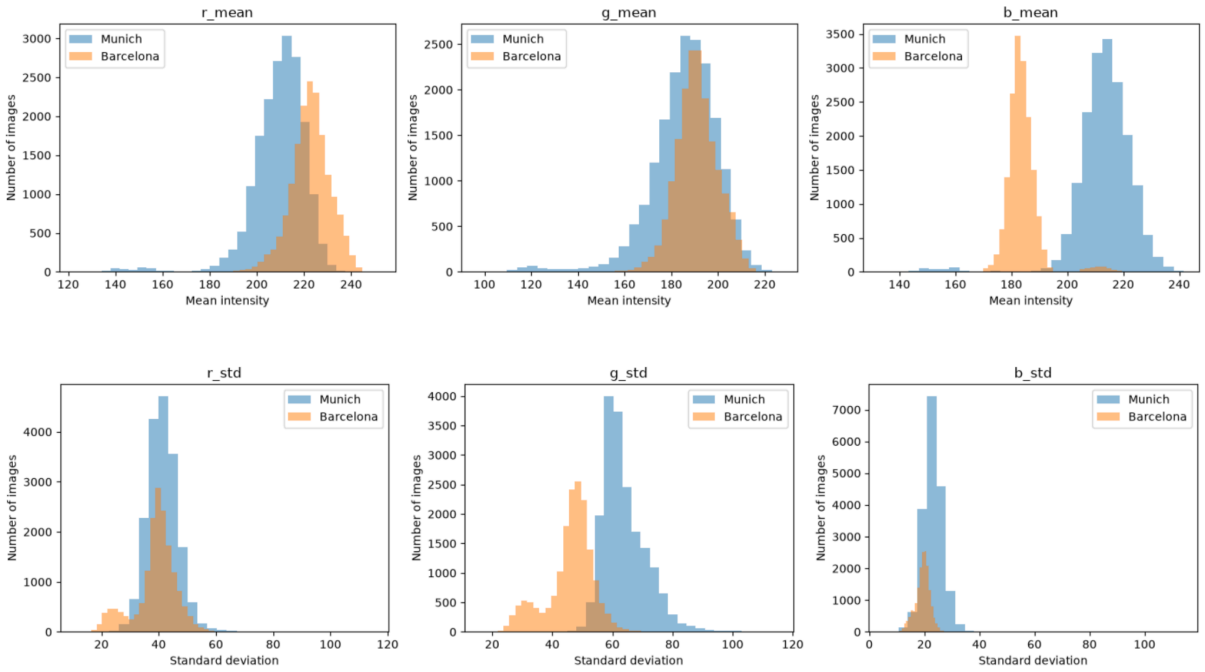
Une comparaison visuelle d'une image par classe permet ensuite d'observer les différences morphologiques entre les cellules ainsi que les différences de rendu entre les deux sources.



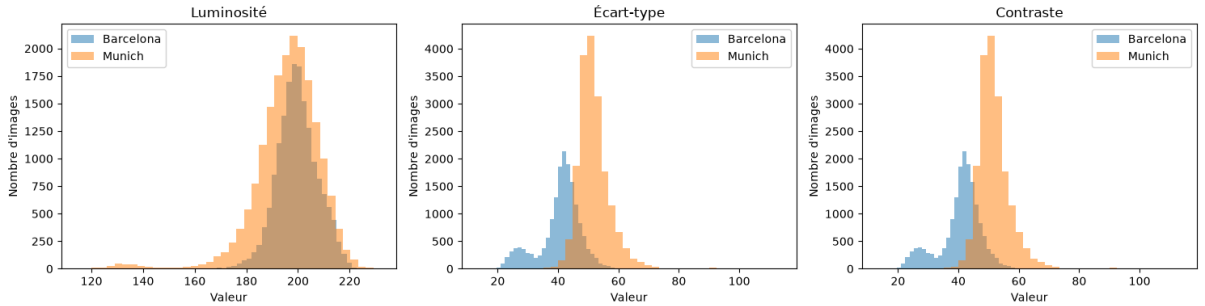
L'analyse des histogrammes de pixels met également en évidence des différences entre les sources. Les distributions des canaux **R, G et B**, ainsi que celles des niveaux de gris, varient selon le dataset et selon le type cellulaire. Ces différences peuvent constituer des variables explicatives pour un modèle, mais elles peuvent également contenir une information liée à la source d'acquisition plutôt qu'à la morphologie de la cellule.

Ce point constitue un risque important pour la classification. En effet, si une classe cellulaire est principalement, voire exclusivement, représentée dans une seule source, le modèle peut apprendre à associer certaines caractéristiques visuelles propres au site d'acquisition à cette classe. Il pourrait alors obtenir de bonnes performances sans réellement apprendre les caractéristiques morphologiques de la cellule. Dans ce cas, une différence de luminosité, de coloration, de résolution ou de contraste pourrait devenir un indice indirect de la classe.

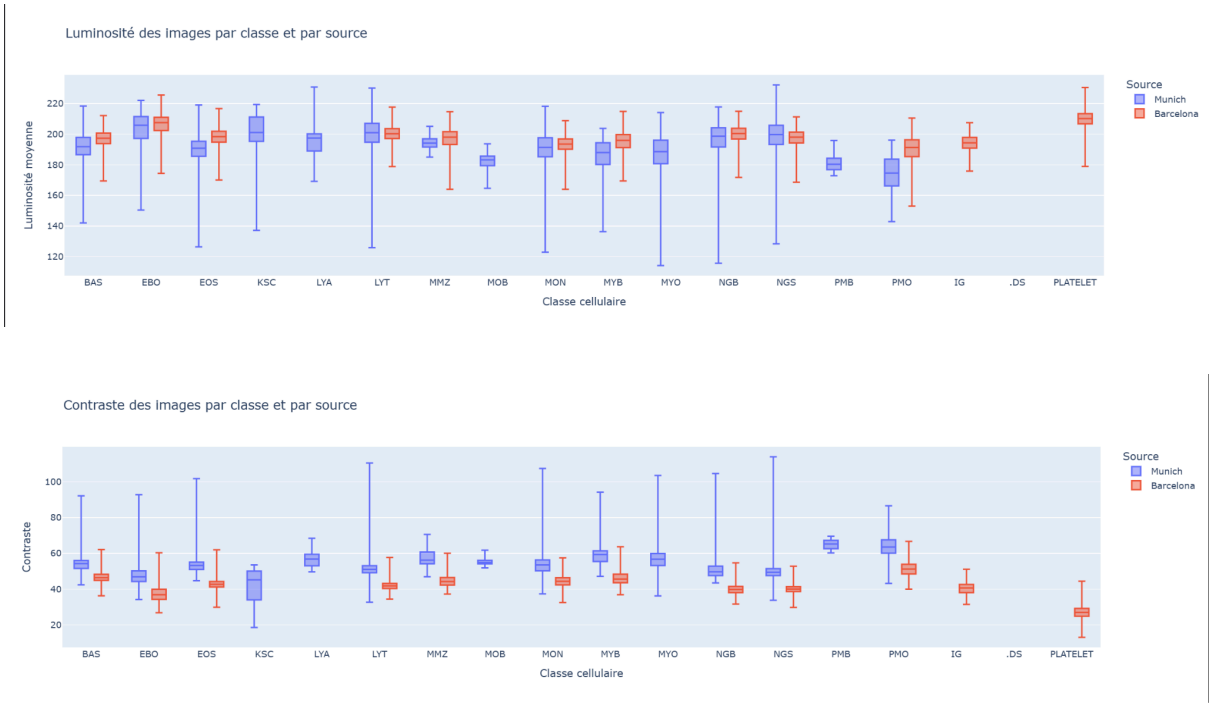
Le modèle risque ainsi de reconnaître le site d'acquisition plutôt que la cellule elle-même. Ce biais peut limiter fortement la généralisation du modèle à une nouvelle source ou à des images acquises dans des conditions différentes. L'analyse du domain gap entre Barcelone et Munich constitue donc un enjeu essentiel avant d'évaluer les performances de classification.



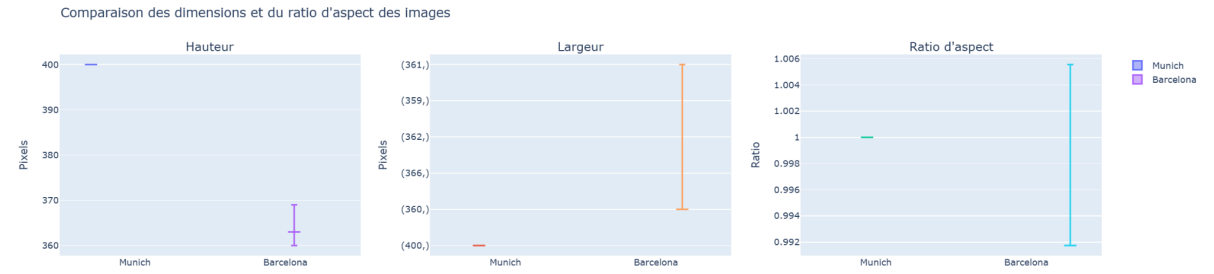
Afin de quantifier ces différences, plusieurs indicateurs ont été calculés pour les images : **luminosité moyenne, contraste et netteté**. Les boxplots montrent des différences de luminosité et de contraste entre les deux sources, ainsi que des variations selon les classes cellulaires.

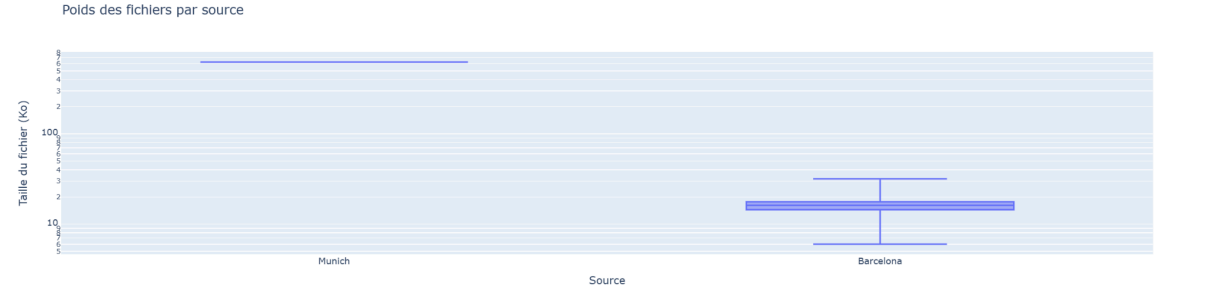


Ces indicateurs permettent également d'étudier les relations entre certaines caractéristiques des images. La luminosité et le contraste présentent des distributions différentes selon les classes et les sources, tandis que la netteté permet d'identifier les images présentant potentiellement un problème de mise au point.

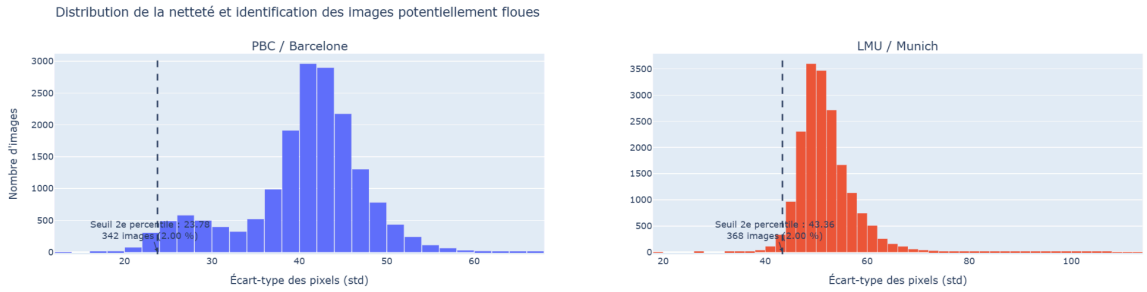


La dimension des images constitue une autre différence importante entre les sources. Les images LMU sont homogènes en **400 × 400 pixels**, tandis que les images PBC présentent principalement une résolution de **360 × 363 pixels**. Le poids des fichiers est également très différent : le format TIFF utilisé par LMU représente environ **625 Ko par image** dans l'échantillon étudié, contre environ **16 Ko** pour les images JPG de PBC.

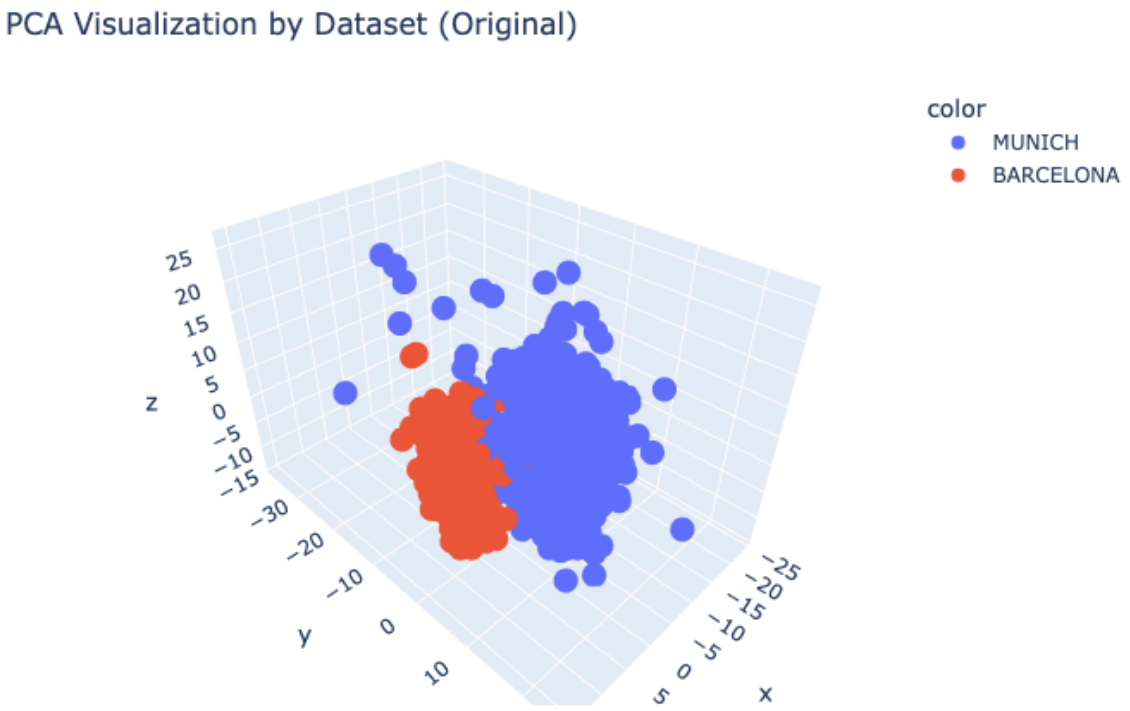




L'analyse de la netteté permet enfin d'identifier les observations situées dans les valeurs les plus faibles. En prenant le **2e percentile** comme seuil de contrôle, 40 images sur 1 963 dans l'échantillon LMU et 48 images sur 2 400 dans l'échantillon PBC sont signalées comme potentiellement floues. Ces observations constituent des points à contrôler, sans être automatiquement considérées comme des erreurs ou supprimées.



Une analyse en composantes principales (PCA) a également été réalisée sur un échantillon d'images afin de visualiser leur organisation dans un espace de dimension réduite. Cette représentation permet notamment d'observer le regroupement des images selon leur source.



Les analyses statistiques réalisées dans cette phase sont principalement **des statistiques descriptives** : effectifs, proportions, moyennes, écarts-types, quantiles et distributions. Elles sont utilisées pour caractériser les données et comparer les deux sources. Aucun test statistique inférentiel n'a été retenu à ce stade ; l'objectif est principalement d'identifier les caractéristiques susceptibles d'influencer l'apprentissage.

Ces observations orientent la modélisation sur trois points principaux : la forte différence de distribution des classes nécessite de contrôler le déséquilibre du jeu d'apprentissage ; les différences de luminosité, de contraste et de rendu entre les sources doivent être prises en compte afin de limiter l'apprentissage d'informations propres à la source ; enfin, la présence de quelques images potentiellement problématiques justifie un contrôle de la qualité des données avant l'entraînement final. L'objectif de la modélisation sera donc d'évaluer dans quelle mesure ces caractéristiques influencent réellement la capacité du CNN à distinguer les différentes classes cellulaires.

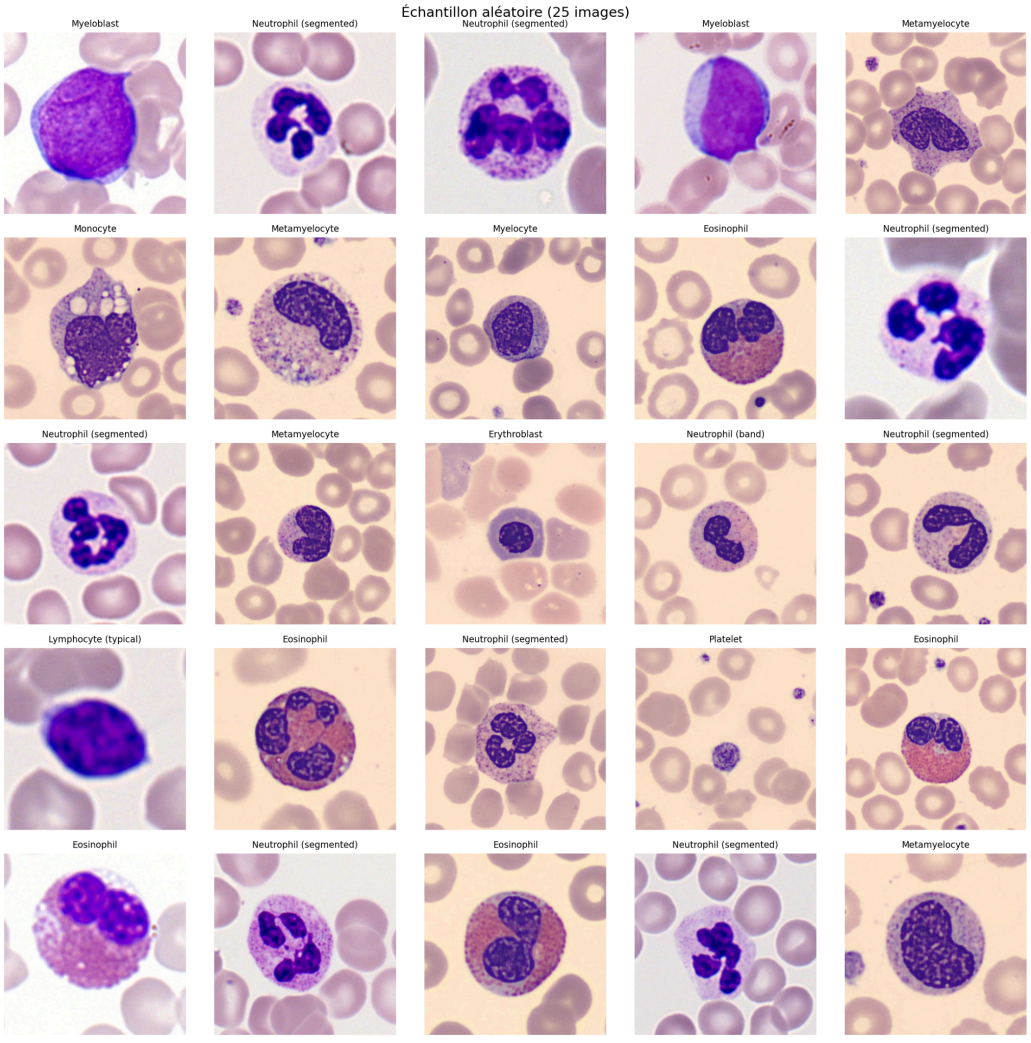
2.4 Synthèse des problèmes identifiés et des réponses envisagées

Problème identifié	Risque pour la classification	Réponse / expérimentation
Déséquilibre des classes	Le modèle peut favoriser les classes majoritaires et négliger les classes minoritaires.	Sélection des classes, rééchantillonnage et pondération des classes.
Différences entre PBC et LMU	Le modèle peut apprendre des caractéristiques propres à la source plutôt qu'à la cellule.	Étude du domain gap et test de transformations de pré-processing.
Différences de luminosité / contraste / colorimétrie	Le modèle peut utiliser des caractéristiques liées à l'acquisition comme indices de classification.	Égalisation, CLAHE, Reinhard, CORAL, etc.
Résolutions et formats différents	Les modèles peuvent être sensibles aux caractéristiques techniques des images.	Recadrage et redimensionnement en 224 × 224 pixels.
Images potentiellement floues ou de mauvaise qualité	Une mauvaise qualité d'image peut perturber l'apprentissage.	Contrôle de netteté et contrôle qualité avant entraînement.
Classes très peu représentées	Les performances sur ces classes sont difficiles à interpréter et peuvent être instables.	Regroupement ou exclusion de certaines classes trop peu représentées.

3. Pré-processing et préparation des données

3.1 Fusion et contrôle qualité

Les deux sources PBC et LMU sont fusionnées afin de constituer un jeu de données commun pour les expérimentations de classification. Cette étape s'accompagne d'un filtre de qualité appliqué automatiquement aux images afin d'écarter celles présentant une membrane cellulaire percée, plusieurs cellules principales dans le même cadrage ou des éléments de fort contraste en dehors de la cellule principale. Le filtre repose sur des heuristiques de traitement d'image — segmentation par teinte, analyse de forme et contrôle de saturation — calibrées itérativement et contrôlées visuellement sur des échantillons d'exclusions afin de limiter les faux positifs. Les images conservées sont ensuite recadrées automatiquement sur la cellule principale.

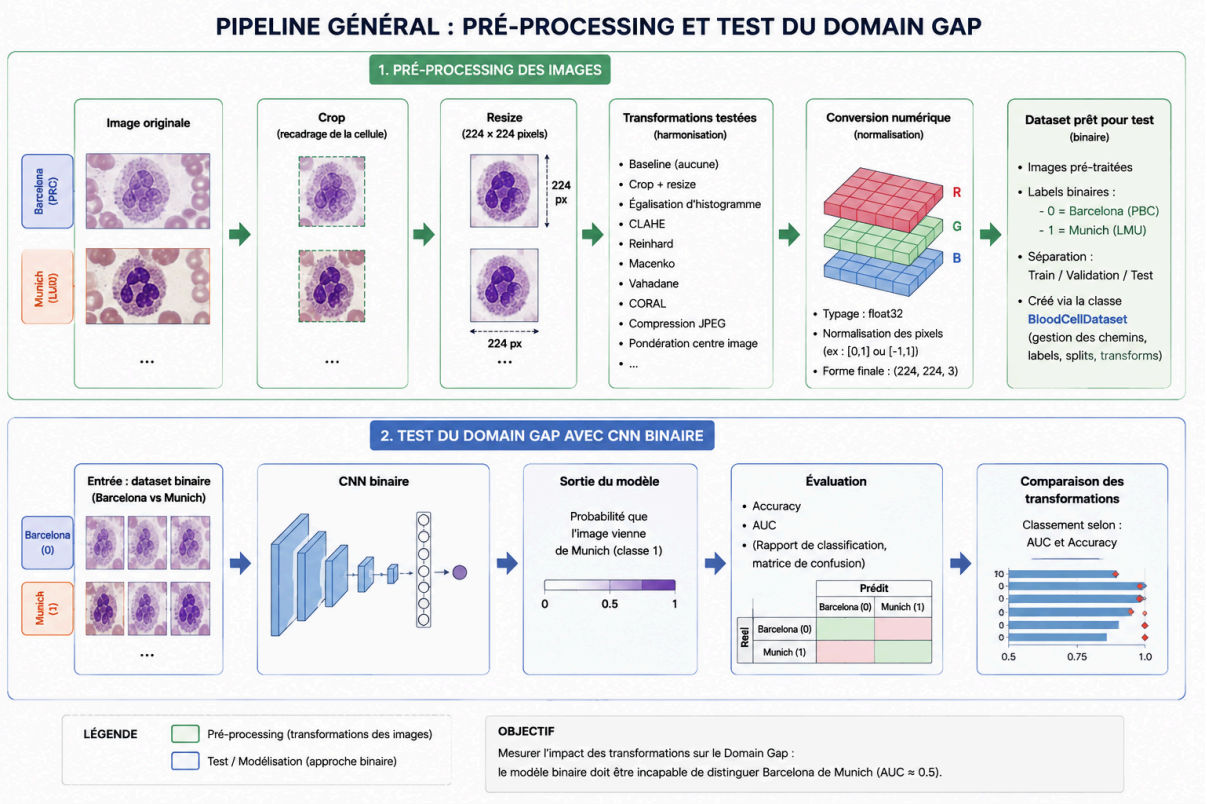


Échantillon aléatoire de 25 images du jeu de données fusionné et filtré

3.2 Standardisation des images

Les images sont ensuite standardisées par recadrage de la cellule, redimensionnement en 224 × 224 pixels et conversion dans un format numérique adapté au CNN. Ces

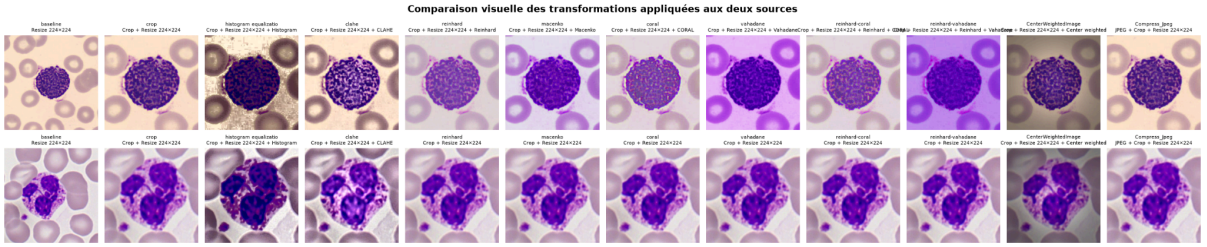
opérations constituent la préparation commune avant l'étude des transformations visant à réduire le domain gap.



Le recadrage et le redimensionnement sont conservés de manière identique entre les différentes configurations afin de comparer l'effet des transformations de pré-processing sans modifier simultanément les autres paramètres de préparation.

3.3 Étude des transformations de pré-processing

Une première série de transformations a été étudiée afin de réduire les différences observées entre les images provenant de Barcelone et celles provenant de Munich. Les transformations testées comprennent notamment l'égalisation d'histogramme, CLAHE, Reinhard, Macenko, Vahadane, CORAL, ainsi que des transformations liées au traitement de l'image telles que la compression JPEG et la pondération du centre de l'image.

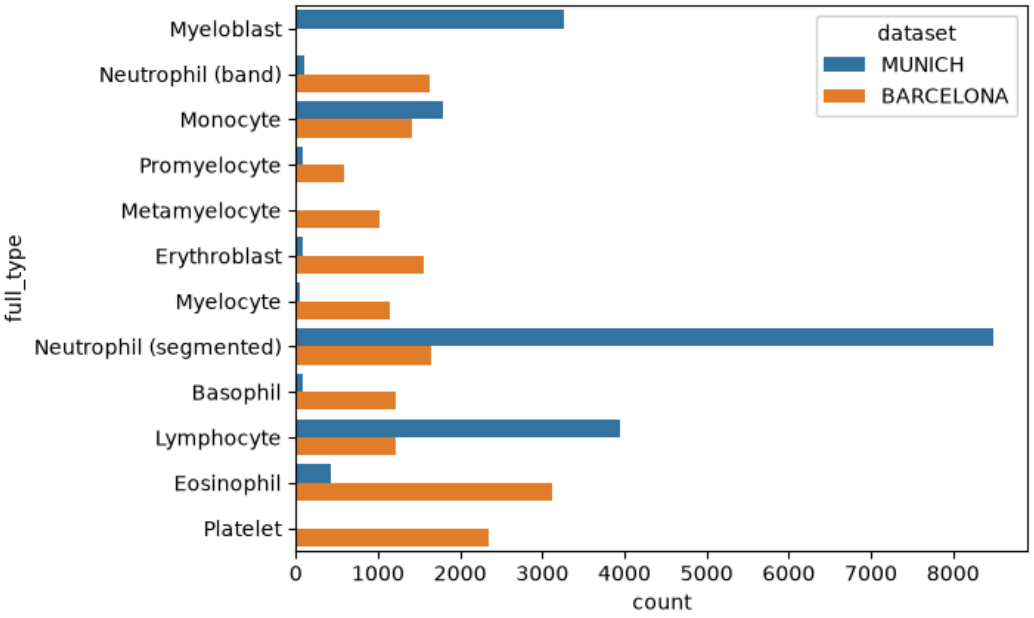


3.4 Sélection des classes

Une autre étape du pré-processing concerne la sélection des classes pour la classification multi-classes. L'objectif est de limiter l'influence de catégories trop peu représentées et

de conserver des classes communes aux deux sources disposant d'un nombre suffisant d'images.

Dans cette étape, les lymphocytes atypiques du dataset LMU, avec seulement 11 images, sont regroupés avec les lymphocytes typiques qui comptent plus de 5 000 images. Les smudge, avec 15 images sans valeur clinique dans le cadre de cette expérimentation, ou les monoblastes, avec 26 images, sont supprimés du jeu de données. Certaines images du dataset PBC correspondent à des neutrophiles ou à des granulocytes immatures sans sous-catégorie associée ; elles ne sont donc pas utilisées dans cette expérimentation.



3.5 Data augmentation

Aucune stratégie de data augmentation n'a été évaluée dans cette première phase mais par la suite dans la partie 4.3 ou l'on a testé la stratégie d'augmentation des données par multiplication des données en équilibrant les classes et les sources avec égalment rotation, flip, et jitter de couleur. Cette piste reste ouverte pour la suite du projet, notamment pour tester la robustesse du modèle face à des variations contrôlées de luminosité, de contraste, d'orientation ou de cadrage, sans créer artificiellement de caractéristiques morphologiques incompatibles avec les cellules étudiées.

4. Modélisation et expérimentations

4.1 Classification binaire par cellule

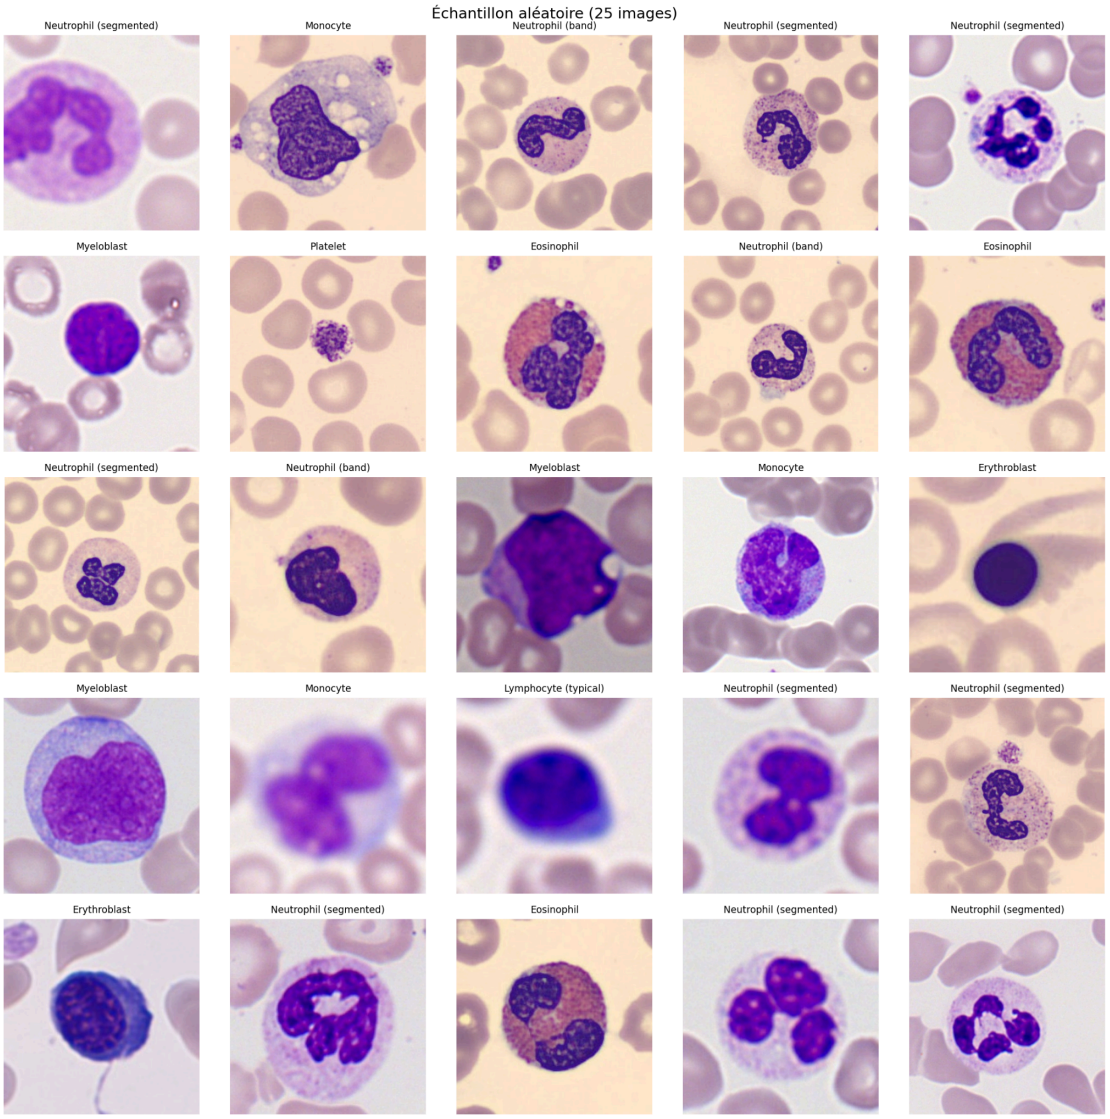
Une première baseline de classification binaire a été mise en place afin d'évaluer la capacité des données à discriminer un type cellulaire de l'ensemble des autres classes. Cette approche consiste à considérer successivement une classe comme classe positive et toutes les autres comme classe négative.

Cette stratégie permet d'obtenir une première évaluation de la **séparabilité des différentes populations cellulaires** et de comparer les difficultés rencontrées selon les

classes. Elle permet également de mettre en évidence d'éventuels problèmes présents dans les données, notamment lorsque certaines erreurs de classification peuvent être associées à des images ambiguës.

Les premières expérimentations ont notamment porté sur les **neutrophiles segmentés** puis sur les **promyélocytes**. Le choix d'une approche binaire permet de se concentrer sur une population cellulaire donnée et d'observer plus précisément sa capacité à être distinguée du reste du jeu de données.

Cette baseline constitue également un premier moyen de vérifier si les caractéristiques présentes dans les images sont suffisamment discriminantes pour permettre une classification. Les résultats obtenus doivent cependant être interprétés avec prudence : une bonne performance de classification ne garantit pas que le modèle s'appuie sur les caractéristiques morphologiques pertinentes de la cellule. En particulier, compte tenu des différences observées entre les sources PBC et LMU, le modèle peut potentiellement exploiter des caractéristiques liées au **site d'acquisition** plutôt qu'à la cellule elle-même.



Second échantillon aléatoire, illustrant la diversité des classes après fusion et filtrage

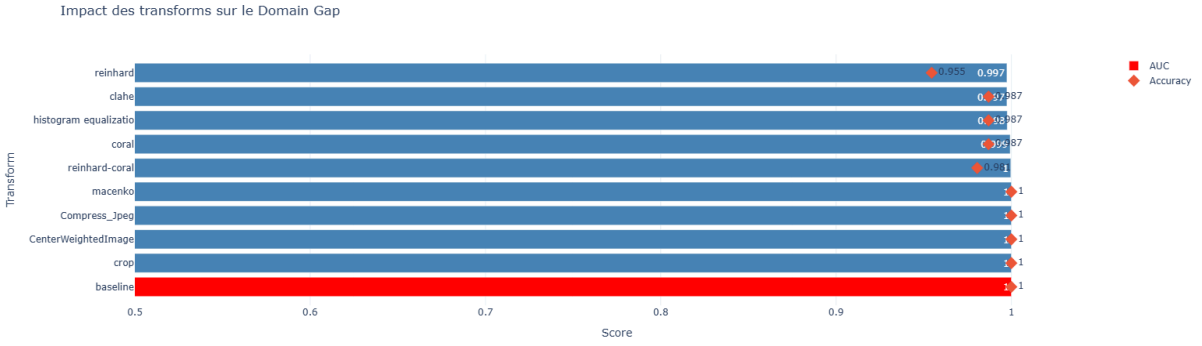
Ces travaux de modélisation, menés en complément de l'exploration des données, apportent ainsi un éclairage supplémentaire sur leur qualité et leur exploitabilité.

Cette problématique est particulièrement importante lorsqu'une classe est sur-représentée dans une source. Le modèle pourrait alors apprendre une association indirecte entre certaines caractéristiques visuelles propres au dataset et la classe cellulaire. L'évaluation du **domain gap** entre les deux sources constitue donc une étape complémentaire nécessaire avant de pouvoir interpréter pleinement les performances de classification.

L'analyse des erreurs obtenues sur cette première baseline a par ailleurs permis d'identifier certains cas correspondant potentiellement à des erreurs d'annotation dans les données sources. Cette observation souligne l'importance de la qualité des labels dans l'évaluation des performances et constitue un point à prendre en compte dans la suite du projet.

4.2 Évaluation du domain gap par CNN binaire

Pour évaluer l'efficacité des transformations, un CNN binaire a été entraîné pour distinguer les deux sources d'images. L'objectif n'était pas encore de classifier les cellules, mais de déterminer si le modèle pouvait toujours identifier leur provenance après transformation. Les résultats montrent que les différentes transformations testées ne permettent pas de supprimer significativement cette information : le CNN conserve une capacité de discrimination très élevée entre les deux sources.

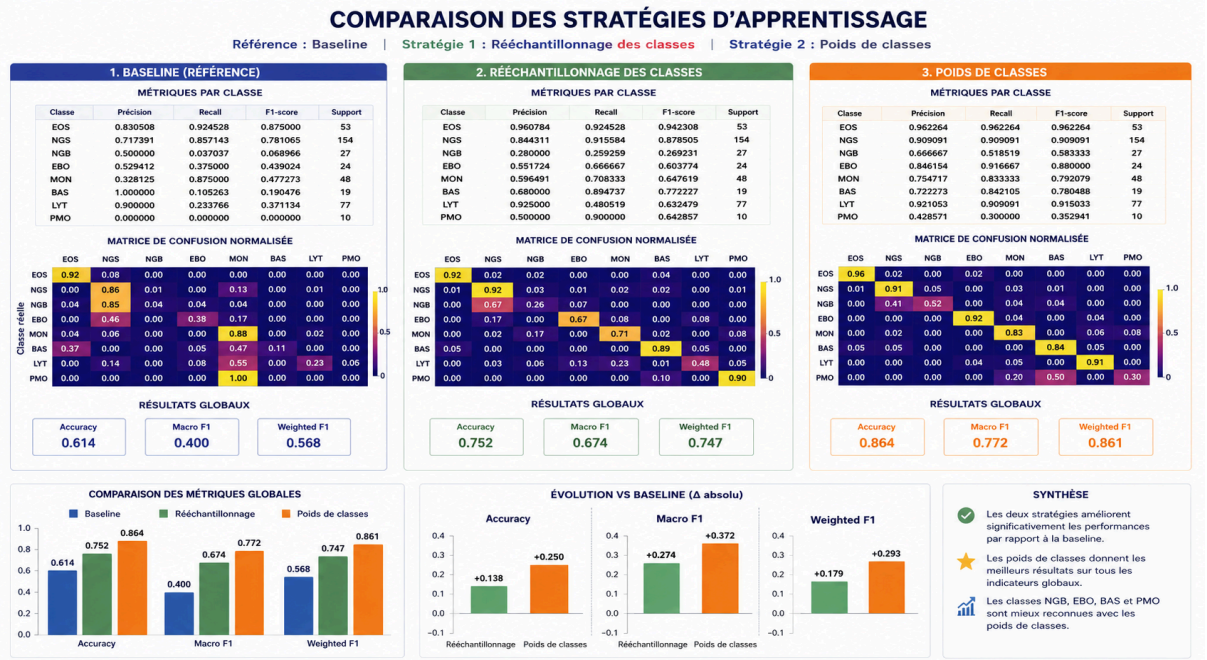


Cette première expérimentation montre donc que les transformations testées individuellement ne suffisent pas à harmoniser complètement les deux sources. De plus, certaines transformations telles que Macenko ou Vahadane ne se sont pas révélées adaptées aux données utilisées. Elles peuvent modifier fortement le rendu des images lorsque les hypothèses de colorimétrie sur lesquelles elles reposent ne sont pas respectées.

4.3 Classification multi-classes et stratégies de rééquilibrage

Le jeu d'entraînement fait ensuite l'objet de différentes stratégies de rééquilibrage : une référence sans rééquilibrage, un rééchantillonnage des classes minoritaires et l'utilisation

de poids de classes lors de l'apprentissage. Cette comparaison permet d'évaluer l'impact du déséquilibre des données sans modifier les jeux de validation et de test.



5. Conclusion et perspectives

Les résultats obtenus au cours de cette première phase permettent de mieux caractériser les limites des données et d'identifier les principaux facteurs susceptibles d'influencer les performances de classification. Les différences entre les sources PBC et LMU restent importantes malgré les différentes transformations testées, tandis que le déséquilibre des classes constitue un enjeu majeur pour la classification multi-classes. Les expérimentations avec les CNN binaires ont également mis en évidence des difficultés à la discriminabilité de certaines classes.

Ces résultats ne permettent toutefois pas de conclure qu'une transformation est systématiquement meilleure qu'une autre pour la classification des cellules. Une transformation peut réduire certaines différences visuelles entre les sources sans nécessairement améliorer la reconnaissance des types cellulaires. Cette distinction est importante, car l'objectif final n'est pas uniquement de réduire le domain gap, mais d'obtenir une classification robuste et généralisable des cellules.

La suite du projet consistera donc à poursuivre l'étude des transformations de pré-processing, mais en les évaluant directement dans le cadre d'un CNN de classification multi-classes. Les différentes configurations seront comparées à partir de métriques adaptées au déséquilibre des classes, notamment le F1-score, afin de déterminer quelles transformations et quelles stratégies de rééquilibrage améliorent réellement la classification des différentes populations cellulaires. Une comparaison avec une approche multi-modèles, notamment des classifieurs binaires, pourra être conservée comme analyse complémentaire si elle apporte une information utile. La data augmentation pourra également être évaluée comme piste complémentaire, avec des transformations contrôlées et compatibles avec la morphologie cellulaire.

6. Références bibliographiques

[1] Acevedo, A., Alférez, S., Merino, A., Puigví, L., & Rodellar, J. (2019). Recognition of peripheral blood cell images using convolutional neural networks. Computer Methods and Programs in Biomedicine, 180, 105020. https://doi.org/10.1016/j.cmpb.2019.105020

[2] Boldú, L., Merino, A., Acevedo, A., Molina, A., & Rodellar, J. (2021). A deep learning model (ALNet) for the diagnosis of acute leukaemia lineage using peripheral blood cell images. Computer Methods and Programs in Biomedicine, 202, 105999. https://doi.org/10.1016/j.cmpb.2021.105999

[3] Zheng, X., Wang, Y., Wang, G., & Liu, J. (2018). Fast and robust segmentation of white blood cell images by self-supervised learning. Micron, 107, 55–71. https://doi.org/10.1016/j.micron.2018.01.010

[4] Acevedo, Andrea; Merino, Anna; Alférez, Santiago; Molina, Ángel; Boldú, Laura; Rodellar, José (2020), “A dataset for microscopic peripheral blood cell images for development of automatic recognition systems”, Mendeley Data, V1, doi: 10.17632/snkd93bnjr.1

[5] Matek, C., Schwarz, S., Marr, C., & Spiekermann, K. (2019). A Single-cell Morphological Dataset of Leukocytes from AML Patients and Non-malignant Controls [Data set]. The Cancer Imaging Archive. https://doi.org/10.7937/tcia.2019.36f5o9ld